

Cartes de Contrôle

Situation d'Apprentissage et d'Évaluation S2.04

Exploitation d'une base de données

Julien Vion

Référentiel et présentation

En quoi consiste cette SAÉ ?

En partant d'un cahier des charges, il faut réaliser et étudier une base de données. À partir d'un jeu d'essais, il doit être proposé une visualisation des informations permettant d'apporter une analyse à l'entreprise. Cette SAÉ permet une première approche complète des aspects de conception, implémentation, administration et exploitation d'une base de données.

Quelles sont les productions de cette SAÉ ?

- Étude des données et visualisation des informations (notebook Jupyter)
- Modèle de données
- Script de création de base de données

Comment se fait le travail ?

Le travail se fera en mode « projet » de 4 étudiants (exceptionnellement 3 ou 5).

Coefficient de pondération

UE 2.4, tous parcours : 38 %


Présentation

Vous travaillez pour une usine qui produit des rouleaux de papier à partir de pâte à papier. L'usine est équipée d'une machine moderne semblable à celle illustrée sur la figure 1. La machine mesure environ 150 m de long, et peut produire près de 100 km de papier par heure sous forme de bobines de 10 m de large.

Pour garantir la qualité du papier produit, la machine est équipée de capteurs tout au long de la chaîne de production, qui permettent aux automates et aux opérateurs de « conduire » la machine. Ces capteurs peuvent par exemple mesurer la vitesse de rotation des bobines, le taux d'humidité ou la température de la pâte à papier, sa couleur (blancheur), etc.



[Photo par Chris Allen, <http://geograph.co.uk>, CC BY SA 2.0]



[Figure par Egmason, Wikimedia, CC BY 3.0]

FIG. 1 : Photo et schéma d'une machine à papier Fourdrinier




FIG. 2 : Exemple de carte de contrôle. Celle-ci permet de visualiser une dérive entre 1 h 00 et 6 h 00, avec 11 points consécutifs au dessus de la moyenne, et 2 points sur les 4 derniers en dehors de l'intervalle de confiance.

[Figure par DanielPenfield, Wikimedia, CC BY-SA 3.0]

La qualité des mesures réalisées par les capteurs est donc très importante pour l'entreprise. Chaque capteur a une marge d'erreur connue et acceptable, mais ils peuvent se dérégler avec le temps ou tomber en panne, générant alors des mesures aberrantes mettant en péril la qualité de la production.

Une équipe de techniciens du laboratoire de l'usine est chargée de contrôler que chaque capteur réalise des mesures correctes. Pour cela, ils réalisent des mesures complémentaires sur des prélèvements, ou viennent faire ponctuellement des mesures manuelles directement sur la machine. Si on constate un écart important entre la mesure réalisée manuellement et la mesure automatique du capteur, celui-ci devra être réétalonné, voire remplacé.

Vous disposez d'une base de données dans laquelle sont stockées toutes les mesures réalisées, automatiquement par les capteurs embarqués sur la machine, ou manuellement par les techniciens.

L'objectif principal de cette SAÉ sera la réalisation de cartes de contrôle à partir de données extraites de cette base de données (section 1).

Les objectifs secondaires de cette SAÉ seront :

- définir des tests statistiques permettant la détection de cartes de contrôle non conformes (section 2),
- créer une base de données qui servira à faire des statistiques sur les taux de pannes des capteurs (section 3).

1 Cartes de contrôle

Le rapport correspondant à cette section compte pour environ 10 % de l'évaluation de la SAÉ.

Dans l'industrie, on utilise des *cartes de contrôle* (*Control Charts* ou *Shewhart Charts* du nom de leur inventeur, pour les laboratoires Bell dans les années 1920) pour visualiser la contrôlabilité d'un système. Les CC consistent à afficher les différentes mesures effectuées en fonction du temps. On ajoute une droite horizontale représentant la moyenne escomptée, et deux droites supplémentaires permettant de visualiser un intervalle « de confiance » dans lequel la plupart des mesures devraient se trouver. Le résultat ressemble à la figure 2.




FIG. 3 : Diagramme de classes de la base de données.

Les données de mesure se trouvent dans la base *capteurs* du serveur *PostgreSQL* iutinfo-sgbd.uphf.fr. La base de données est représenté sur la figure 3.

Model contient un catalogue de modèles de capteurs, automatiques ou manuels. Le champ *unit* contient l'unité de mesure (mm, °C, psi, kg, etc.)

Sensor contient la liste des capteurs automatiques. Le champ *validity* indique la durée pendant laquelle une mesure est exploitable.

Controller contient la liste des instruments de mesure manuels utilisés pour les contrôles.

SensorMeasurement contient toutes les mesures réalisées automatiquement par les capteurs. Il peut y avoir jusqu'à une mesure toutes les 5 secondes sur une période de plusieurs mois, soit plusieurs centaines de milliers de données par capteur.

ControlMeasurement contient toutes les mesures réalisées manuellement par les techniciens.

Votre tâche principale consiste à utiliser les langages Python et SQL pour générer la carte de contrôle d'un capteur de votre choix. Utilisez au maximum le langage SQL : jointures, agrégats, vues, etc.

Vous n'avez pas le droit de créer des vues sur la base de données *Capteurs*, vous devrez travailler sur une base vous appartenant (locale ou *iutinfoXXX*), ou encore utiliser des vues temporaires avec **WITH**. Consultez l'annexe 5 si vous voulez créer une vue sur une table d'une base de données distante.

Votre code devra :

- Pour chaque mesure manuelle du capteur choisi, associer le point de mesure automatique correspondant. Calculez alors la différence entre les deux points : on considère qu'il s'agit d'une mesure de l'erreur.
- Tracez la carte de contrôle (similaire aux figures 2 et 5) pour les points correspondant aux 8 derniers jours (minimum 20 points¹ et maximum 100, ajustez la durée si nécessaire).
- Pour l'ensemble des points du capteur disponibles dans la BDD (pas seulement les points tracés!), calculer la moyenne μ et l'écart-type σ . Normalement, μ doit être très proche de 0. Faites apparaître sur la carte de contrôle une droite horizontale permettant de visualiser la moyenne constatée μ , ainsi que des droites permettant de visualiser l'intervalle $[\mu - 2\sigma, \mu + 2\sigma]$.
- Il doit être possible de changer facilement le capteur visualisé (en changeant une constante).

Vous intégrerez votre programme Python/SQL dans un *notebook Jupyter*. Pour accéder au serveur *PostgreSQL* depuis votre programme, vous utiliserez le module Python *psycopg*. Pour dessiner la carte de contrôle, vous utiliserez le module *matplotlib*. Tout le code Python et SQL réalisé devra être écrit intégralement en anglais. Cela concerne notamment le choix des noms des fonctions, variables, noms de fichier, noms de tables, commentaires, etc.

¹Garantir un minimum de 20 points n'est pas trivial, vous pouvez mettre cette spécification de côté dans un premier temps.




FIG. 4 : Distribution normale centrée

2 Statistiques

2.1 Visualisation des marges d'erreur

Le rapport correspondant à cette section compte pour environ 8 % de l'évaluation de la SAÉ.

Si les capteurs étaient parfaits, la différence entre la valeur mesurée par le capteur automatique et la mesure réalisée en laboratoire devrait toujours être de 0. Malheureusement, tous les capteurs ont une marge d'erreur plus ou moins importante. Il est donc attendu que chaque différence mesurée soit légèrement supérieure ou inférieure à 0.

Tracez dans votre *notebook* un histogramme présentant la répartition des mesures du capteur choisi dans la section précédente.

Vous devriez voir apparaître une forme de « cloche » caractéristique de la loi de probabilité dite « normale », comme sur la figure 4. L'intérêt est qu'on connaît parfaitement la répartition théorique des valeurs soumises à cette loi. Elle dépend de la moyenne (ici 0 mais on peut facilement « décaler » la courbe en retirant μ à chaque point) et de l'écart-type σ . Les pourcentages indiqués sur la figure 4 correspondent à la répartition théorique des points.

1. **À l'aide d'un programme Python/SQL, comptez le nombre de points compris entre $-\sigma$ et $+\sigma$ du capteur que vous étudiez. Est-ce que cela correspond bien à environ 68 % de l'ensemble des points ?**
2. **Faites de même pour l'intervalle $[-2\sigma, +2\sigma]$ pour confirmer qu'environ 95 % des points se trouvent dans cet intervalle.**
3. **Faites de même pour l'intervalle $[-3\sigma, +3\sigma]$ pour confirmer qu'environ 99,7 % des points se trouvent dans cet intervalle.**
4. **Déduisez-en, pour chacun des cas précédents, la répartition théorique des points situés *en dehors* de l'intervalle étudié.**

Pour les sections suivantes, nous considérons que tous les capteurs, s'ils fonctionnent correctement, ont une marge d'erreur qu'il est possible de modéliser en utilisant la loi normale. Ainsi, la *probabilité* qu'un point d'être compris dans l'intervalle $[-\sigma, +\sigma]$ est de 68 %, celle qu'un point d'être dans l'intervalle $[-2\sigma, +2\sigma]$ est de 95 %, etc.

2.2 p -valeur

Le rapport correspondant à cette section compte pour environ 10 % de l'évaluation de la SAÉ.

Pour simplifier le travail des techniciens, il faut un moyen de mettre automatiquement en évidence les défaillances de capteurs visibles sur les cartes de contrôle. Pour cela, on détermine des *règles* que les mesures doivent respecter pour être considérée conformes. Par exemple, si, sur une période donnée, trop de points se trouvent en dehors d'un intervalle de confiance choisi, alors le capteur est probablement défaillant au cours de cette période.

Il faut veiller à éviter que les règles ne génèrent trop de *faux positifs* (capteur identifié comme défaillant alors qu'il ne l'est pas) ou *faux négatifs* (capteur identifié comme correct alors qu'il ne l'est pas). Pour nous aider à évaluer théoriquement un règle de détection, on peut déterminer la probabilité de celle-ci à se déclencher en se référant à une loi statistique connue. La probabilité de faux positif est appelée p -valeur.

Par exemple, on décide d'une règle spécifiant que si 6 points consécutifs sont du même côté de la moyenne, alors il faut vérifier le capteur. On peut déduire des résultats de la section précédente que chaque point a 50 % de chances d'être au-dessus de la moyenne, et 50 % de chances d'être en dessous. Si le capteur n'est pas défaillant, la probabilité qu'ont 6 points consécutifs d'être du même côté de la moyenne est donc de $2 \cdot 0,5^6 < 0,04$. Autrement dit, la règle a moins de 4 % de chances de faux positif. Cela signifie que si la règle n'est pas respectée, le capteur a de grandes chances d'être défaillant.

Pour plus de souplesse, on veut pouvoir travailler non seulement sur les n derniers points, mais aussi sur k points parmi les n derniers. Par exemple, la probabilité qu'au moins 12 des 15 derniers points se situent au-dessus de la moyenne est de 1,76 %. **Selon vous, comment a-t-on obtenu ce résultat ? Quelle est la probabilité qu'au moins 15 points sur les 20 derniers se situent du même côté de la moyenne ?**

Cette technique est utilisée en recherche médicale pour déterminer si un traitement est efficace, ou plus généralement en sciences expérimentales pour évaluer la conformité entre les observations et la théorie. Dans les publications scientifiques, on considère généralement qu'une p -valeur inférieure à 0,05 est statistiquement significative.

Une règle ayant p -valeur supérieure à 0,05 aurait trop de faux positifs. Par exemple, une règle détectant 3 points consécutifs du même côté de la moyenne se déclencherait beaucoup trop souvent sans raison ($p = 0,25$).

Même si la p -valeur ne présume pas du taux de faux négatifs, on considère qu'une règle ayant une p -valeur trop faible (par exemple inférieure à 0,01) risquerait de se déclencher trop tard. Par exemple, une règle détectant 8 points consécutifs du même côté de la moyenne ne serait pas suffisamment sensible ($p < 0,008$).

Pour chacune des règles suivantes, calculez et justifiez la p -valeur. Implémentez la règle en Python/SQL, en utilisant des noms de fonctions, variables, commentaires, etc., en anglais. Pour chacune des règles, un message clair doit s'afficher dans le Notebook si elle est déclenchée :

- au moins 8 points sur les 10 derniers du même côté de la moyenne,
- au moins 2 points sur les 7 derniers en dehors de l'intervalle $[-2\sigma, +2\sigma]$,
- au moins 7 points sur les 10 derniers en dehors de $[-\sigma, +\sigma]$.

Enfin, proposez et implémentez une règle de détection de défaillance originale, avec une p -valeur comprise entre 0,01 et 0,05.

Si vous le souhaitez, vous pouvez estimer la p -valeur expérimentalement en générant des données de test. Utilisez le package Python `numpy.random.Generator.normal` pour générer des données respectant une loi normale.




FIG. 5 : Carte de contrôle d'un capteur en cours de dérive

2.3 Dérive et régression

Le rapport correspondant à cette section compte pour environ 8 % de l'évaluation de la SAÉ.

On peut souvent voir qu'un capteur est en train de se dérégler quand on observe une *dérive* sur la carte de contrôle, c'est-à-dire plusieurs points consécutifs croissants ou décroissants. Cependant, une règle détectant, par exemple une série de points tous croissants ou décroissants n'est pas très satisfaisante, puisqu'il suffit d'un point mal orienté pour que l'alerte ne soit pas déclenchée.

Une solution est de calculer la *régression linéaire* des 10 derniers points de la carte de contrôle. Si le coefficient directeur de la droite de régression est trop important (à déterminer), on peut détecter une dérive.

Un exemple est présenté sur la figure 5 : aucun des 10 derniers points n'est consécutivement croissant ni décroissant, mais le calcul d'une droite de régression met en évidence la dérive.

Faites apparaître la droite de régression sur la carte de contrôle du Notebook, et utilisez le coefficient directeur comme base d'une nouvelle règle de détection de défaillance implémentée en Python/SQL, en utilisant des noms de fonctions, variables, commentaires, etc., en anglais.

Évaluez expérimentalement la p -valeur de votre règle en utilisant des données générées aléatoirement.

3 Base de données

Le rapport correspondant à cette section représente 15 % de l'évaluation de la SAÉ.

L'usine voudrait avoir des statistiques sur la fiabilité des capteurs. À chaque fois qu'un capteur est mis en service, réétalonné ou mis au rebut, il faut en garder trace.

Proposez une extension de la base de données de la figure 3 pour stocker ces données, sous la forme d'un diagramme de classes.

Vous n'avez pas le droit de créer des tables sur la base de données *Capteurs*, vous devrez travailler sur une base vous appartenant (locale ou *iutinfoXXX*). Consultez l'annexe 5 si vous voulez calculer une jointure entre des tables de deux bases de données différentes.

Proposez et testez des requêtes qui calculent, pour chaque modèle de capteur :

1. le nombre moyen de réétalonnages par an (déduisez-en le temps moyen entre deux réétalonnages),

2. la proportion de ceux qui n'ont pas été mis au rebut un an après leur mise en service (taux de survie à un an),
3. la proportion de ceux qui n'ont ni été mis au rebut, ni réétalonnés un mois après leur mise en service.

4 Évaluation

1. Réalisez un Notebook Jupyter présentant vos calculs statistiques, vos modèles, vos requêtes, et le résultat de vos tests (sections 3 et 4).
2. Réalisez un rapport PDF présentant votre travail de bases de données (section 5). Il devra notamment comprendre le diagramme de classes de votre extension, vos requêtes (SQL et/ou arbre relationnel) et vos tests. Décrivez et justifiez en français toutes vos réalisations. Le diagramme de classes et le code SQL lui-même devra être en anglais.

Vous pouvez également, si vous le souhaitez, intégrer cette partie à votre Notebook Jupyter. En Mark-Down, utilisez la commande `![alt text](file)` pour intégrer l'image de votre diagramme de classes, et éventuellement de vos arbres relationnels, à votre Notebook.

3. Préparez une présentation orale (en français) de vos résultats. La durée de la présentation doit être de 9 à 11 minutes. La soutenance permettra de valoriser votre Notebook et votre rapport.
4. Une séance en fin de SAÉ sera consacrée à une *évaluation individuelle écrite*. Chaque membre du projet devra être capable de décrire la manière dont une tâche donnée a été réalisée, *même si elle ne lui était pas affectée dans le cadre de la gestion du projet*. Vous devrez également être capables de répondre à des questions « de cours » et faire des exercices-types de bases de données et de statistiques qui ont été mis en œuvre dans le cadre de cette SAÉ. **Cette évaluation représente environ 50 % de l'évaluation de la SAÉ.**

5 Annexe : accès aux données d'une base distante

Vous n'avez pas le droit d'ajouter ou modifier des tables ou des vues de la base *Capteurs*. Pour cela, vous devez travailler sur votre propre base (locale ou *iutinfoXXX*).

*Ne cherchez pas à copier les données des tables *ControlMeasurement* ou *SensorMeasurement* dans votre base de données, elles sont trop volumineuses (plusieurs Go).*

Si nécessaire, il est possible de créer des vues ou des jointures (mais pas des clés étrangères) entre deux tables de bases différentes en utilisant le *Foreign Data Wrapper* de PostgreSQL.

Voici la démarche :

1. Déclaration de la base de données distante

```
CREATE SERVER Capteurs
FOREIGN DATA WRAPPER postgres_fdw
OPTIONS (
    host 'iutinfo-sgbd.uphf.fr',
    dbname 'capteurs');
```

2. Déclaration de l'utilisateur distant

```
CREATE USER MAPPING FOR iutinfoXXX  
SERVER Capteurs  
OPTIONS (  
    user 'iutinfoXXX',  
    password 'XXX');
```

Adaptez le nom d'utilisateur et le mot de passe en fonction de vos identifiants fournis en début d'année.

3. Déclaration de la table distante

```
CREATE FOREIGN TABLE Controller (  
    controllerId int,  
    modelId int,  
    serialNumber text  
) SERVER Capteurs;
```

Vous pouvez alors utiliser la table Controller comme s'il s'agissait d'une table locale. Faites de même pour les autres tables dont vous pourriez avoir besoin pour cette section de la SAÉ.

N.B. : il n'est pas possible de déclarer une contrainte de clé étrangère entre deux tables distantes. Dans ce cas, vous ne serez pas sanctionné si vous créez une clé étrangère sans la contrainte.